INFORME TÉCNICO

Predicción del éxito comercial de películas

Clasificación con SVM, Árbol de Decisión, Random Forest y Gradient Boosting

Comparación de modelos de Machine Learning sobre el conjunto TMDb 5000

Asignatura	Machine Learning
Actividad	Proyecto Integrador - Clasificación del éxito comercial de películas
Modelos	SVM | Árbol de Decisión | Random Forest | Gradient Boosting
Dataset	TMDb 5000 Movies y TMDb 5000 Credits
Fuente	Kaggle - kaggle.com/datasets/tmdb/tmdb-movie-metadata
Variable objetivo	Éxito si recaudación >= 2 x presupuesto
Estudiante(s)	Dariana Pol Aramayo

1. Formulación del problema

El desempeño en taquilla resulta incierto al planificar una película. Este proyecto estudia si variables de producción y créditos permiten clasificar su desempeño comercial, y qué familia de modelos ofrece un equilibrio adecuado entre rendimiento, costo e interpretabilidad.

Variable objetivo: éxito (clase 1) si la recaudación es al menos dos veces el presupuesto de producción; fracaso según el umbral (clase 0) en caso contrario. El valor 2 se fija antes del entrenamiento. Es una aproximación operativa, no un cálculo de ganancia neta: faltan gastos y participación del estudio en la recaudación.

Objetivos medibles: comparar accuracy, precisión, recall, F1 y ROC-AUC; incorporar F1 macro para ponderar ambas clases; medir entrenamiento e inferencia en el mismo equipo; interpretar errores e importancia de variables y justificar una selección.

Datos y alcance

Los archivos TMDb de películas y créditos contienen 4,803 registros cada uno. Se unen uno a uno por identificador. Se conservan 3,229 películas con presupuesto y recaudación positivos y fecha válida; se excluyen 1,574. Quedan 1,809 éxitos y 1,420 fracasos operativos.

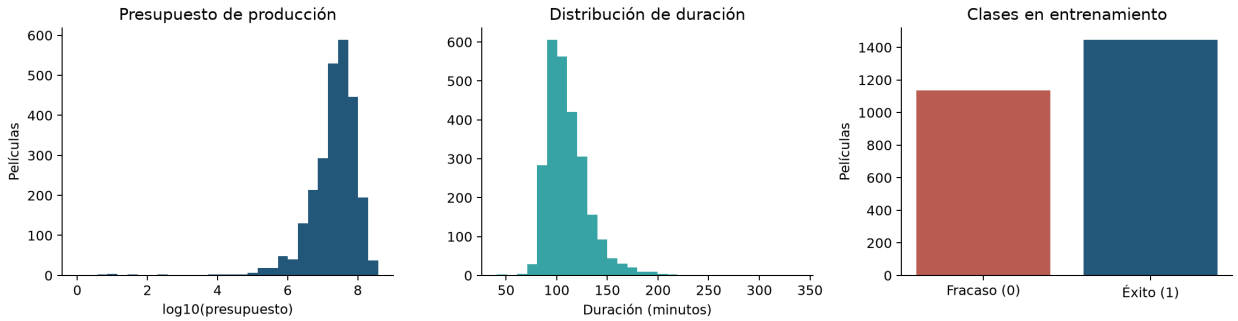
La muestra conservada abarca 1916-09-04 a 2016-09-09. Los resultados describen esta colección histórica y no demuestran generalización a estrenos futuros. Se asume disponibilidad previa al estreno de presupuesto, duración, fecha y créditos; la colección no certifica una captura histórica de esos valores en ese momento.

Resultado principal: el protocolo de validación y costo seleccionó RandomForest. Su F1 macro en prueba fue 0.617, con accuracy 0.630. La selección y sus límites se desarrollan en las siguientes páginas.

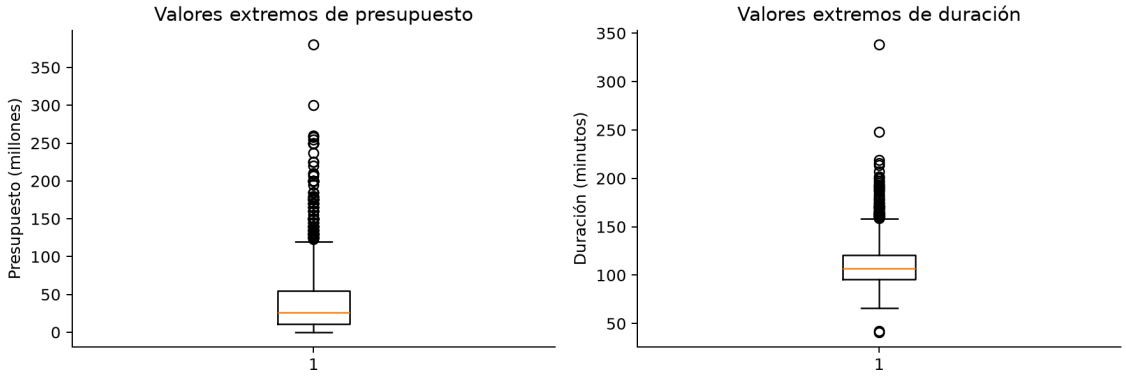
2. Calidad y estadística descriptiva

Se detectan 1,037 presupuestos en cero y 1,427 recaudaciones en cero. Estas cifras se solapan; no deben sumarse como películas distintas. Un cero no se interpreta como fracaso verificado y no se imputa una recaudación para construir etiquetas. No se excluyen registros por carecer de página web o sinopsis, variables que no se utilizan.

Variable (entrenamiento)	Mediana	Media	Mínimo	Máximo
Presupuesto (millones)	26.00	41.24	0.000001	380.00
Recaudación (millones)	57.22	121.59	0.000007	2,787.97
Duración (minutos)	107.00	110.91	41.00	338.00



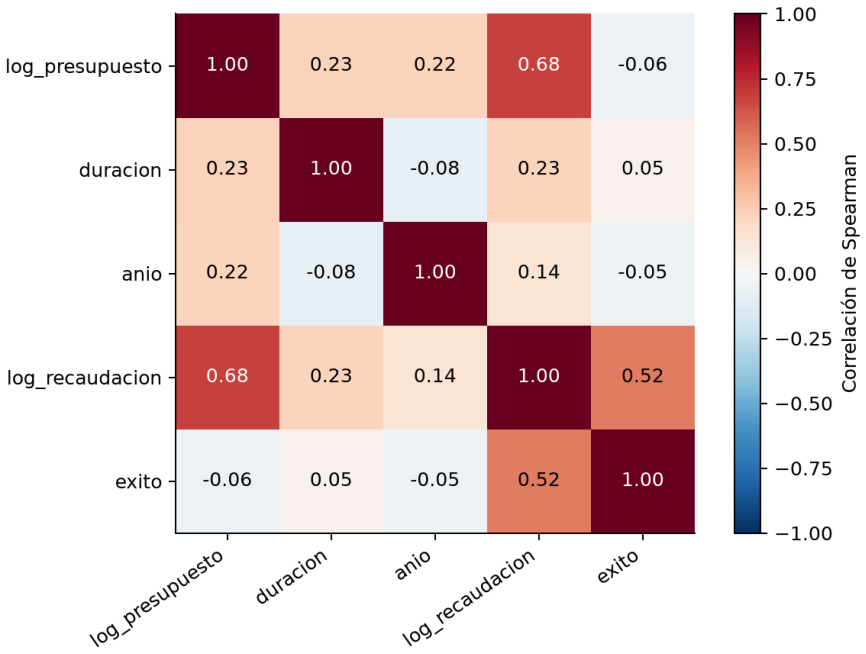
El análisis exploratorio se realiza sobre entrenamiento. Presupuesto y recaudación presentan valores extremos; una media superior a la mediana indica asimetría. La duración se conserva en minutos. La presencia de presupuestos grandes no basta para considerar un registro erróneo.



Se usa log1p del presupuesto para reducir su asimetría sin borrar superproducciones. La imputación numérica posterior utiliza medianas aprendidas dentro de cada fold.

Los mínimos positivos de presupuesto y recaudación son sospechosamente bajos. La regla mayor que cero no garantiza validez financiera: se requiere revisar esos registros en la fuente antes de una aplicación real. Se conservan en este primer experimento sin inventar correcciones.

Correlaciones y variables explicativas



La correlación de Spearman entre logaritmo de presupuesto y recaudación es 0.68. Es una asociación descriptiva, no un efecto causal. La recaudación y la etiqueta aparecen aquí para entender el fenómeno; no entran a los predictores.

Variables: logaritmo de presupuesto, duración, año, mes, idioma, primer país de producción registrado y géneros múltiples. Se agregan trayectorias previas de los primeros cinco actores y de los directores. El primer país es una simplificación para coproducciones.

La trayectoria cuenta créditos con fecha estrictamente anterior en el conjunto de entrenamiento de cada fold. No usa etiquetas ni recaudaciones. Se utiliza el logaritmo de uno más el promedio de créditos anteriores del elenco. Es experiencia observada en una muestra parcial, no popularidad ni filmografía completa.

Prevención de fuga: se excluyen revenue como predictor, vote_average, vote_count y popularity. No se garantiza que las tres últimas variables existieran con esos valores antes del estreno. Identificadores de películas, títulos y cocientes con recaudación tampoco son predictores.

3. Protocolo experimental y modelos no lineales

La división es aleatoria estratificada: 2,583 películas de entrenamiento y 646 de prueba, con semilla 42. Se emplean tres folds estratificados para ajuste. Todos los modelos comparten observaciones, particiones y F1 macro como criterio de validación.

Cada pipeline ajusta trayectoria, imputación y codificación dentro del fold de entrenamiento. Los géneros se representan por presencia/ausencia. Mes, idioma y país se codifican mediante one-hot, agrupando categorías con menos de 20 casos en entrenamiento. SVM escala solo las variables numéricas; los árboles no requieren escalado.

SVM: kernel RBF para fronteras no lineales. C controla penalización/regularización y gamma el alcance de las observaciones. Se exploran C = 0.1, 1, 10 y gamma = scale, 0.01, 0.1. ROC-AUC utiliza decision scores; no se activa calibración de probabilidades.

Árbol: se comparan Gini y entropía, profundidades 3, 6 e ilimitada y mínimos de 5 o 20 muestras por hoja. Limitar profundidad y tamaño de hojas controla sobreajuste, con posible pérdida de flexibilidad.

Modelo	Parámetros seleccionados
SVM	C=1, gamma=scale
Arbol	criterion=gini, max_depth=None, min_samples_leaf=20

El árbol facilita explicar reglas condicionales. Las reglas exportadas muestran solo los primeros niveles y no se convierten en afirmaciones causales sobre géneros o presupuestos. La importancia agrupada se presenta junto a la evaluación.

Referencia mínima

Un DummyClassifier predice siempre la clase mayoritaria del entrenamiento. Su accuracy en prueba es 0.560, F1 macro 0.359 y ROC-AUC 0.500. Compararlo evita confundir un resultado aparentemente alto con una mejora real frente a una estrategia trivial.

4. Bagging y Boosting

Random Forest: árboles con bootstrap y selección aleatoria de variables. Se exploran 150/300 árboles, profundidad 8/ilimitada y mínimo de 2/8 muestras por hoja. Este conjunto reduce la dependencia de un árbol individual y se evalúa mediante CV y OOB.

La accuracy OOB del bosque final es 0.616. Es un diagnóstico adicional del estimador sobre características construidas a partir del entrenamiento completo; no sustituye la validación del pipeline y sus transformaciones dentro de cada fold.

Gradient Boosting: árboles secuenciales que corrigen errores del conjunto. Se exploran learning_rate de 0.03/0.1, profundidad 2/3 y máximo de 200/400 estimadores, con mínimo de 10 observaciones por hoja. Se admite esta familia en la rúbrica; XGBoost es una alternativa.

La parada temprana usa una validación interna del 20% del entrenamiento, paciencia de 15 iteraciones y tol = 0.001. Se detiene según la pérdida interna sin usar prueba. El modelo final empleó 49 estimadores efectivos. Las transformaciones no supervisadas se ajustan en el entrenamiento externo del pipeline, no en la prueba.

Modelo	Parámetros seleccionados
RandomForest	max_depth=None, min_samples_leaf=2, n_estimators=300
Boosting	learning_rate=0.1, max_depth=3, n_estimators=200

Validación y estabilidad

Modelo	F1 macro train CV	F1 macro CV	Desv. CV	Brecha
SVM	0.728	0.585	0.008	0.142
Arbol	0.689	0.575	0.020	0.114
RandomForest	0.979	0.600	0.010	0.379
Boosting	0.704	0.577	0.008	0.127

RandomForest presenta la mayor brecha entre entrenamiento y validación (0.379). Es una señal de posible sobreajuste, no una medición pura de varianza. La desviación entre tres folds describe estabilidad de esta partición; no es un intervalo de confianza.

5. Rendimiento y costo comparados

Las métricas se calculan en la misma prueba reservada. Precisión, recall y F1 corresponden a éxito (clase 1). F1 macro pondera ambas clases por igual. ROC-AUC usa probabilidades o scores continuos, nunca etiquetas binarias.

Modelo	Accuracy	Precisión	Recall	F1	F1 macro	ROC-AUC
SVM	0.661	0.676	0.760	0.715	0.648	0.700
Arbol	0.576	0.624	0.613	0.618	0.571	0.588
RandomForest	0.630	0.653	0.727	0.688	0.617	0.687
Boosting	0.642	0.660	0.746	0.700	0.629	0.682

El entrenamiento del pipeline completo se repite tres veces y se informa su mediana. La predicción mide clases del lote completo, con un calentamiento previo, y excluye métricas/gráficos. Los estimadores y búsquedas utilizan un solo trabajo; las bibliotecas numéricas de esta ejecución se limitaron a un hilo. La búsqueda se informa aparte.

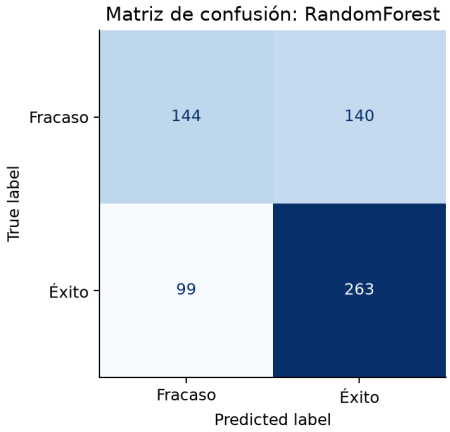
Modelo	Entrenamiento (s)	Predicción lote (s)	ms/película	Búsqueda (s)
SVM	1.4327	0.3999	0.6191	58.10
Arbol	0.3593	0.0705	0.1091	23.58
RandomForest	3.8368	0.0942	0.1458	59.48
Boosting	0.4612	0.0270	0.0418	34.68

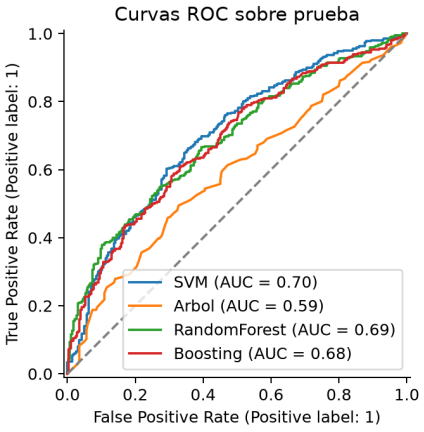
Criterio previo de selección: maximizar F1 macro de validación; entre modelos a menos de 0.01 del máximo, elegir el menor tiempo mediano de entrenamiento. La tolerancia expresa una preferencia operativa y no equivalencia estadística. La selección no usa métricas de prueba.

El protocolo selecciona RandomForest. El mayor F1 macro observado en prueba corresponde a SVM; esa observación se describe sin cambiar parámetros ni selección. Una aplicación con exigencias de latencia debería definir también un límite de inferencia antes de comparar.

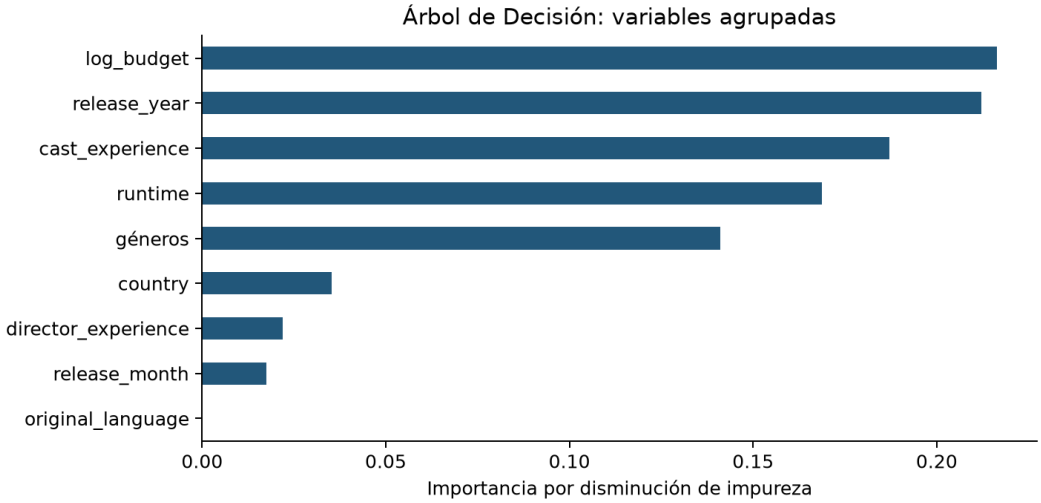
Los tiempos dependen del equipo, versiones y carga del sistema. Tres repeticiones reducen ruido, pero no permiten trasladar estos valores a otro equipo ni asegurar que diferencias mínimas se repitan.

6. Errores e importancia de variables



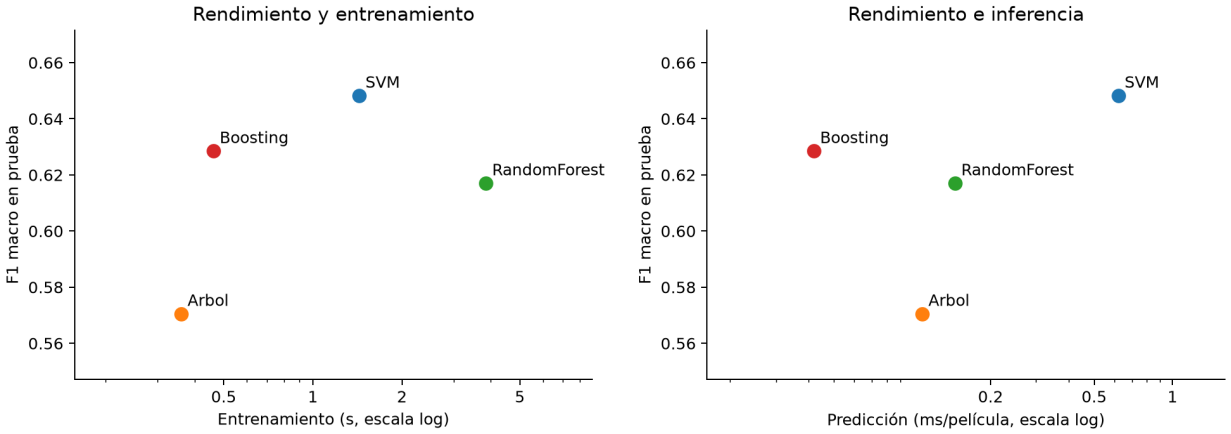


En el modelo seleccionado se observan 140 fracasos clasificados como éxitos y 99 éxitos clasificados como fracasos. En una decisión de producción, el primer error puede favorecer una inversión equivocada y el segundo una oportunidad perdida. No se dispone de costos monetarios para ponderarlos aquí.



Las mayores importancias agrupadas del árbol son log_budget (0.216), release_year (0.212), cast_experience (0.187). Se suman las columnas de cada variable original, incluyendo géneros y categorías. La importancia por impureza puede favorecer variables con más opciones de división; no prueba causalidad.

7. Discusión y conclusiones



RandomForest responde al criterio de selección establecido: F1 macro CV de 0.600, F1 macro de prueba 0.617, entrenamiento mediano de 3.837 s y predicción por película de 0.146 ms. Frente a Dummy, la diferencia de F1 macro en prueba es +0.258.

Random Forest mejora F1 macro de validación en 0.015 frente a SVM, pero tarda 2.68 veces más en entrenar. En prueba, SVM obtiene accuracy 0.661 y F1 macro 0.648, superiores a los del bosque. La clasificación de modelos cambia entre validación y prueba: no hay un ganador que domine en todos los criterios. Hace falta una evaluación adicional reservada o un protocolo más amplio para una elección de producción.

SVM depende de regularización y escala; un árbol profundo aumenta flexibilidad y riesgo de sobreajuste. Bagging suele disminuir la varianza de árboles individuales, y Boosting reduce errores mediante adiciones secuenciales. Los resultados de validación, y no estas tendencias generales, sustentan la decisión concreta. La ganancia de un ensamblado debe evaluarse junto al tiempo y la facilidad de explicar decisiones.

Limitaciones: definición aproximada de éxito; selección de películas con cifras financieras conocidas; ausencia de gastos de marketing y reparto de ingresos; falta de ajuste por inflación; créditos parciales; y presupuesto/fecha/duración históricos sin captura previa certificada. La división aleatoria no prueba desempeño sobre películas futuras.

Recomendaciones: construir una prueba temporal con ajuste exclusivo en el pasado; evaluar sensibilidad con umbrales 1.5 y 2.5 conservando particiones por ID; incorporar antecedentes históricos completos y gastos de marketing; y definir costos de errores o límites de latencia según una aplicación real. Cualquier cambio guiado por esta prueba requiere una nueva evaluación reservada.

8. Revisión de funcionamiento y estabilidad

Se ejecutó el notebook completo desde el comienzo y se verificaron 9 controles de integridad y metodología: particiones separadas, etiqueta consistente, ausencia de predictores posteriores, transformaciones finitas, dimensiones correctas, coherencia entre predicción individual y en lote, scores para ROC-AUC y trayectoria anterior al estreno.

Las métricas de los cuatro modelos coinciden con la ejecución anterior: máxima diferencia absoluta 0. Los tiempos se vuelven a medir y pueden cambiar. La inferencia con categorías y personas nuevas también se completó sin errores.

Se identifican 18 registros con presupuesto o recaudación positivos inferiores a 1.000. Se exportan para revisión de fuente, sin eliminarlos después de observar la prueba ni inventar correcciones.

Modelo	Accuracy	IC 95% accuracy	F1 macro	IC 95% F1 macro
SVM	0.661	0.625 a 0.695	0.648	0.612 a 0.683
Arbol	0.576	0.539 a 0.616	0.571	0.533 a 0.610
RandomForest	0.630	0.596 a 0.667	0.617	0.581 a 0.654
Boosting	0.642	0.607 a 0.680	0.629	0.590 a 0.668

Intervalos percentiles de 1.000 remuestreos bootstrap pareados y estratificados de la prueba. La diferencia de F1 macro SVM menos Random Forest tiene intervalo [-0.0005, 0.0620]. Incluye cero: no se sostiene una superioridad concluyente de SVM frente al bosque con este diagnóstico.

Los intervalos están condicionados a los modelos entrenados y a la composición de esta prueba. No incluyen incertidumbre de reentrenamiento ni constituyen una nueva prueba independiente. Los errores se comprueban además mediante ejemplos explícitos de acierto y error en el notebook.

Modelo	F1 macro medio	Desv. entre particiones	Rango observado
Arbol	0.559	0.017	0.526 a 0.583
Boosting	0.575	0.022	0.539 a 0.606
RandomForest	0.590	0.027	0.548 a 0.636
SVM	0.586	0.022	0.559 a 0.632

Estabilidad: tres folds por tres repeticiones, únicamente en entrenamiento y con parámetros congelados. Es un diagnóstico postselección; estos datos participaron antes en el ajuste, por lo que no es validación anidada ni desempeño independiente. No se cambia el ganador original.

9. Correspondencia con la rúbrica

La revisión contrasta los ocho criterios de la rúbrica con evidencia ejecutada. Esta correspondencia no predice una nota: la evaluación académica también depende de la interpretación y defensa del estudiante.

Criterio y peso	Cobertura	Evidencia
1. Problema (10%)	Cubierto	Contexto, etiqueta operacional, objetivos medibles y límites de la rentabilidad. Notebook: inicio y secciones 3 y 14.
2. Estadística (12%)	Cubierto	Descriptiva, distribuciones, outliers, correlación, división estratificada y escalado diferencial. Secciones 2 a 5.
3. SVM (12%)	Cubierto	RBF justificado, C/gamma ajustados por CV, métricas y tiempos. Secciones 6, 10 y 11.
4. Árbol (12%)	Cubierto	Gini/entropía, profundidad y hojas, CV, costo, reglas e importancia. Secciones 7 y 12.
5. Bagging (15%)	Cubierto	Random Forest con bootstrap, ajuste, OOB y evaluación de rendimiento, estabilidad, costo e interpretabilidad. Secciones 8, 10, 13 y 17.
6. Boosting (15%)	Cubierto	Learning rate y estimadores, profundidad, parada temprana, métricas y costo. Secciones 9 a 11.
7. Discusión (14%)	Cubierto	Tabla de cuatro modelos, rendimiento/costo, sesgo-varianza y selección original diferenciada del mejor resultado en prueba. Secciones 12, 13 y 16.
8. Conclusiones (10%)	Cubierto	Respuesta cuantificada al objetivo, limitaciones y mejoras concretas. Sección 14 y discusión del informe.

Selección con varios criterios: F1 macro y costo definen la regla formal. La estabilidad se contrasta con dispersión de CV y el diagnóstico repetido. La interpretabilidad favorece al árbol para explicar reglas, aunque su desempeño es menor; el bosque se explica mediante importancias y errores. La gran brecha del bosque obliga a reconocer sobreajuste. Ningún criterio aislado garantiza utilidad real.

F1 de una sola clase: Dummy alcanza F1 de éxito 0.718 porque anuncia éxito para todas las películas. Su F1 macro es 0.359 y no detecta ningún fracaso. Por eso las conclusiones se basan en varias métricas, con prioridad de F1 macro, y no se afirma mejorar al baseline en todas ellas.

Estado de entrega: notebook ejecutado, tablas y gráficos presentes; informe dentro del máximo de 15 páginas. Faltan nombres/datos académicos y el enlace compartido del notebook en Colab. El estudiante confirmó la fuente TMDb en Kaggle. La defensa debe presentar resultados moderados, no prometer rentabilidad ni aciertos sobre futuros estrenos.

10. Reproducibilidad y referencias

El notebook incluye código, explicaciones y salidas ejecutadas. Se guardan métricas, búsquedas de hiperparámetros, partición por identificador, tiempos repetidos, reglas, importancias y gráficos en resultados/. El resumen en JSON permite comprobar las cifras del informe.

Dependencia	Versión
pandas	3.0.5
numpy	2.5.2
scikit-learn	1.9.0
matplotlib	3.11.1

Semilla: 42. Validación: tres folds. Entrenamiento/prueba: 80/20. Repeticiones de costo: tres. Las versiones y huellas SHA-256 de ambos archivos se registran en entorno.json. Los datos originales no se modifican.

Notebook local: Proyecto_Integrador_Peliculas.ipynb. Antes de entregar, subirlo al medio solicitado por el docente e incorporar aquí su enlace público o compartido con acceso verificado. Completar también nombres y datos académicos.

Fuentes

Fuente de los CSV confirmada por el estudiante: TMDB 5000 Movie Dataset en Kaggle. Archivos utilizados: tmdb_5000_movies.csv y tmdb_5000_credits.csv. La segunda colección evaluada inicialmente no se combina con estos datos. Las huellas SHA-256 identifican la copia local usada en el experimento.

Rúbrica de la asignatura: ML-B2-C18-Rubrica_Proyecto_Integrador.docx. Exige cuatro modelos, métricas de rendimiento, tiempos, discusión, notebook ejecutado e informe de máximo 15 páginas.

Scikit-learn: prevención de fugas y pipelines: https://scikit-learn.org/stable/common_pitfalls.html

Scikit-learn: Random Forest y OOB: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html

Scikit-learn: Gradient Boosting y parada temprana: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingClassifier.html

TMDb: señales usadas para popularidad: https://developer.themoviedb.org/docs/popularity-and-trending

Este informe describe una ejecución concreta del experimento. Las conclusiones deben revisarse al volver a ejecutarlo: tiempos y, con otras versiones, pequeñas diferencias de resultados pueden cambiar.